



MODÈLES CAUSAUX HIÉRARCHIQUES : COMPRÉHENSION, IMPLÉMENTATION ET EXPÉRIMENTATION

Projet Scientifique Collectif (PSC)

Année académique 2025–2026

Étudiant 1 Anass Ettahiri

Étudiant 2 Yasser Oufqir

Étudiant 3 Simon Patry

Étudiant 4 Aymen El Ouadrhiri

Étudiant 5 [Membre du groupe 5]

Encadré par : [Nom du superviseur]






Figure 1 – Les trois motifs fondamentaux des Modèles Causaux Hiérarchiques (HCM) étudiés dans ce PSC. Chaque modèle capture des unités i (plaque extérieure) contenant des sous-unités j (plaque intérieure en pointillé). U_i est une variable latente confondante au niveau de l’unité, A_{ij} le traitement de la sous-unité, Y_{ij} le résultat de la sous-unité.

Résumé

L'inférence causale à partir de données hiérarchiques (imbriquées) est un défi fondamental dans les sciences naturelles et sociales. Ce rapport décrit les travaux réalisés lors du PSC sur les Modèles Causaux Hiérarchiques (HCM), un cadre introduit par Weinstein et Blei (2023) qui étend les Modèles Causaux Structurels (SCM) et les Modèles Graphiques Causaux (CGM) pour traiter des données collectées sur des sous-unités imbriquées à l'intérieur d'unités. Notre travail a couvert trois aspects complémentaires : (1) une compréhension approfondie et une redérivation du cadre théorique—transformations de graphes (*collapse*, *augment*, *marginalize*), identification par do-calcul, et théorie de l'estimation ; (2) une implémentation Python complète du pipeline HCM, articulée autour des fonctions `collapse`, `suggest_augment_for_outcome`, `augment_collapsed_model`, `marginalize_augmented_model`, `identify_effect` et `estimate_causal_effect` ; et (3) une validation expérimentale par des études de récupération de l'Effet Moyen du Traitement (ATE) sur des données synthétiques générées à partir de modèles *ground-truth* connus. L'implémentation est organisée comme un package Python (`hierarchicalcausalmodels`) et reproduit les principaux résultats de l'article sur les trois motifs canoniques HCM : CONFONDANT, CONFONDANT & INTERFÉRENCE, et INSTRUMENT.

TABLE DES MATIÈRES

1	Introduction	6
1.1	Motivation et contexte	6
1.2	Objectifs du PSC	6
1.3	Structure du rapport	6
2	Rappels : Inférence Causale Classique	7
2.1	Modèles Causaux Structurels (SCM)	7
2.2	Modèles Graphiques Causaux (CGM)	7
2.3	Do-Calcul et ses Axiomes	7
2.4	Critère de porte arrière (Backdoor)	8
2.5	Critère de porte avant (Front-door)	9
2.6	Ajustement par Variables Instrumentales (VI)	10
2.7	Limitations avec les données hiérarchiques	11
3	Modèles Causaux Hiérarchiques : Théorie	12
3.1	Modèles Causaux Structurels Hiérarchiques (HSCM)	12
3.2	Trois Motifs Canoniques HCM	13
3.3	Variables Q et Modèles Graphiques Causaux Hiérarchiques	13
4	Pipeline d'Identification HCM	14
4.1	Vue d'ensemble	14
4.2	Étape 1 : <code>collapse(hscm)</code>	14
4.3	Étape 2 : <code>suggest_augment_for_outcome</code>	15

4.4	Étape 3 : <code>augment_collapsed_model</code> (variable par variable)	16
4.5	Étape 4 : <code>marginalize_augmented_model</code>	17
4.6	Étape 5 : <code>identify_effect</code>	18
5	Estimation	19
5.1	Vue d'ensemble	19
5.2	Étape 6 : <code>estimate_causal_effect</code> — Estimation numérique de l'estimande	20
5.3	Estimation par unité (<code>ConditionalDensityEstimator</code>)	21
5.4	Estimateur ATE : cas CONFONDANT	21
5.5	Estimateur neuronal : <code>MLPRegressorPerUnit</code>	21
6	Implémentation	22
6.1	Structure du package	22
6.2	<code>HSCMParametric</code> : Spécification du modèle	23
6.3	Pipeline complet : exemple bout-en-bout	23
7	Résultats Expérimentaux	25
7.1	Récupération de l'ATE : motif CONFONDANT	25
7.2	Suite de tests do-calcul	25
7.3	Récupération de l'ATE : les trois motifs	26
7.4	Galerie do-calcul : estimation de l'ATE sur 13 configurations	26
7.5	Suite de benchmarks : 9 scénarios avec vérité terrain	27
8	Application à Project STAR : Estimation Causale Hiérarchique	29
8.1	Présentation et motivation	29
8.2	Données et schéma HCM	30
8.3	Pipeline d'analyse	30
8.4	Résultats de la découverte causale	31
8.5	Explicabilité prédictive	31
8.6	Référence économétrique : réplcation de Krueger (1999)	32
8.7	HCM v1 : École $\rightarrow$ Élève	32
8.8	HCM v2 : Classe/Enseignant $\rightarrow$ Élève	33
8.9	Synthèse comparative	34
8.10	Apport des HCM pour STAR	34
9	Discussion	35
9.1	Enseignements clés	35
9.2	Limitations et problèmes ouverts	36
10	Conclusion	36
A	Transformations de graphes complètes	38
A.1	CONFONDANT : transformation complète	39
A.2	CONFONDANT ET INTERFÉRENCE : transformation complète	39
A.3	INSTRUMENT : transformation complète	40

1

INTRODUCTION

1.1 MOTIVATION ET CONTEXTE

Un défi fondamental en inférence causale est que de nombreux jeux de données sont hiérarchiques : les observations ne sont pas des unités indépendantes mais des sous-unités imbriquées dans des unités plus grandes. Considérons des élèves au sein d'écoles, des cellules au sein de patients, ou des citoyens au sein d'États. Dans de tels contextes, les variables au niveau de l'unité (par ex., le budget d'une école) peuvent affecter les variables au niveau de la sous-unité (par ex., les notes d'élèves individuels), et vice versa. Les outils classiques d'inférence causale—Modèles Causaux Structurels (SCM), do-calcul, ajustement par porte arrière/avant—sont construits pour des données plates, non hiérarchiques. Lorsque les données sont hiérarchiques, agréger simplement les données de sous-unités en résumés au niveau de l'unité (par ex., moyennes de classe) jette des informations cruciales pour l'identification.

Ce PSC est centré sur l'article *Hierarchical Causal Models* d'Eli N. Weinstein et David M. Blei (2023), qui propose un cadre systématique pour l'inférence causale avec des données imbriquées. L'idée clé est que la structure des données hiérarchiques peut souvent *permettre* l'identification causale dans des situations où elle serait impossible avec des données non hiérarchiques.

1.2 OBJECTIFS DU PSC

Notre PSC avait trois objectifs principaux :

1. **Compréhension théorique** : Lire, comprendre et redériver le cadre mathématique des HCM, incluant les définitions de graphes, les transformations collapse/augment/marginalize, l'extension du do-calcul aux HCM, et la théorie de l'estimation.
2. **Implémentation** : Construire un package Python modulaire et complet implémentant le pipeline HCM—de la spécification du modèle à l'identification puis à l'estimation—en suivant la théorie de l'article.
3. **Validation** : Valider l'implémentation en récupérant des Effets Moyens du Traitement (ATE) connus sur des jeux de données synthétiques générés à partir de HCM paramétriques pour les trois motifs principaux.

1.3 STRUCTURE DU RAPPORT

Ce rapport est organisé comme suit. La Section 2 fournit un arrière-plan sur l'inférence causale classique, incluant les SCM, les CGM, et le do-calcul avec ses axiomes. La Section 3 présente

le cadre théorique des HCM. La Section 4 détaille le pipeline d'identification HCM étape par étape. La Section 5 couvre le pipeline d'estimation. La Section 6 détaille notre implémentation Python. La Section 7 présente les résultats expérimentaux. La Section 10 conclut.

2

RAPPELS : INFÉRENCE CAUSALE CLASSIQUE

2.1 MODÈLES CAUSAUX STRUCTURELS (SCM)

Définition 1 (Modèle Causal Structurel (SCM)). *Un Modèle Causal Structurel (SCM) est un tuple $\mathcal{M} = (\mathbf{V}, \mathbf{U}, \mathcal{F}, p(\mathbf{U}))$ où :*

- $\mathbf{V} = \{V_1, \dots, V_k\}$ est l'ensemble des variables observées endogènes.
- $\mathbf{U} = \{U_1, \dots, U_k\}$ est l'ensemble des variables exogènes (bruits).
- $\mathcal{F} = \{f_1, \dots, f_k\}$ est l'ensemble des équations structurelles : $V_i = f_i(\text{pa}(V_i), U_i)$, où $\text{pa}(V_i)$ désigne les parents de V_i dans le graphe acyclique dirigé (DAG) $\mathcal{G}$.
- $p(\mathbf{U}) = \prod_i p(U_i)$ est une distribution produit sur des variables de bruit indépendantes.

Un SCM induit une distribution jointe sur $\mathbf{V}$ et, via l'opérateur *do*, une famille de distributions interventionnelles. L'intervention $\text{do}(V_i = v)$ dans un SCM consiste à remplacer l'équation structurelle de V_i par la constante $V_i = v$, coupant ainsi toutes les influences entrantes.

2.2 MODÈLES GRAPHIQUES CAUSAUX (CGM)

Définition 2 (Modèle Graphique Causal (CGM)). *Un Modèle Graphique Causal (CGM) est une paire $(\mathcal{G}, p)$ où $\mathcal{G}$ est un DAG et p est une distribution jointe markovienne par rapport à $\mathcal{G}$. Chaque variable se factorise comme $p(\mathbf{V}) = \prod_i p(V_i | \text{pa}(V_i))$.*

Les CGM supportent le *do-calcul* pour le raisonnement interventionnel : l'intervention $\text{do}(V_i = v)$ coupe tous les arcs entrants vers V_i et fixe sa valeur à v . On note $\mathcal{G}_{\overline{X}}$ le graphe obtenu en supprimant tous les arcs entrant dans X , et $\mathcal{G}_{\underline{X}}$ celui obtenu en supprimant tous les arcs sortant de X .

2.3 DO-CALCUL ET SES AXIOMES

Définition 3 (Identifiabilité). *L'identification est le problème d'exprimer une quantité interventionnelle $p(Y | \text{do}(A = a))$ uniquement en termes de la distribution observationnelle $p(\mathbf{V})$.*

Une quantité causale est dite identifiable si elle peut être calculée de manière unique à partir de la distribution observationnelle, pour tout SCM compatible avec le graphe.

Le do-calcul de Pearl [2] fournit un système complet de règles pour manipuler des expressions interventionnelles. Il est fondé sur la notion de *d-séparation* dans des graphes modifiés.

Théorème 1 (Do-Calcul de Pearl — Trois Règles). Soit $\mathcal{M}$ un SCM avec graphe $\mathcal{G}$, et soient X, Y, Z, W des ensembles disjoints de variables. Les trois règles suivantes sont valides :

Règle 1 — Insertion/Suppression d’observations :

$$p(Y \mid \text{do}(X), Z, W) = p(Y \mid \text{do}(X), W) \quad \text{si } (Y \perp\!\!\!\perp Z \mid X, W)_{\mathcal{G}_{\overline{X}}}. \quad (1)$$

Interprétation : On peut ignorer Z dans le conditionnement si Y et Z sont *d-séparés* dans le graphe où les arcs entrant dans X sont supprimés. Cette règle permet d’insérer ou de supprimer des observations non pertinentes.

Règle 2 — Échange action/observation :

$$p(Y \mid \text{do}(X), \text{do}(Z), W) = p(Y \mid \text{do}(X), Z, W) \quad \text{si } (Y \perp\!\!\!\perp Z \mid X, W)_{\mathcal{G}_{\overline{X}, \underline{Z}}}. \quad (2)$$

Interprétation : Une intervention sur Z peut être remplacée par une simple observation de Z lorsque Y et Z sont *d-séparés* dans le graphe où les arcs entrant dans X et les arcs sortant de Z sont supprimés. Cette règle formalise le passage de l’interventionnel à l’observationnel.

Règle 3 — Suppression d’actions :

$$p(Y \mid \text{do}(X), \text{do}(Z), W) = p(Y \mid \text{do}(X), W) \quad \text{si } (Y \perp\!\!\!\perp Z \mid X, W)_{\mathcal{G}_{\overline{X}, \overline{Z(W)}}}, \quad (3)$$

où $Z(W)$ désigne les nœuds de Z qui ne sont pas ancêtres de W dans $\mathcal{G}_{\overline{X}}$. Interprétation : Une intervention sur Z est sans effet sur Y si Z n’a aucun chemin actif vers Y dans le graphe approprié.

Ces trois règles sont *complètes* : tout effet causal identifiable peut être dérivé par application successive de ces règles [2]. Le système est implémenté dans notre pipeline via la bibliothèque **pyAgrum**, qui automatise l’application du do-calcul sur les graphes collapsés et augmentés des HCM.

2.4 CRITÈRE DE PORTE ARRIÈRE (BACKDOOR)

Définition 4 (Chemin de porte arrière). Un chemin de porte arrière de A vers Y dans $\mathcal{G}$ est un chemin qui commence par un arc entrant dans A (c’est-à-dire qui « remonte » vers un ancêtre de A). Ces chemins transmettent une association confondante entre A et Y sans passer par des effets causaux directs.

Définition 5 (Critère de porte arrière). Un ensemble de variables observées $\mathbf{Z}$ satisfait le critère de porte arrière par rapport à (A, Y) dans $\mathcal{G}$ si :

- (i) $\mathbf{Z}$ ne contient aucun descendant de A ,
- (ii) $\mathbf{Z}$ bloque tous les chemins de porte arrière de A vers Y .

Formule d’ajustement par porte arrière. Si $\mathbf{Z}$ satisfait le critère de porte arrière par rapport à (A, Y) , alors l’effet causal est identifiable :

$$p(Y = y \mid \text{do}(A = a)) = \sum_{\mathbf{z}} p(Y = y \mid A = a, \mathbf{Z} = \mathbf{z}) p(\mathbf{Z} = \mathbf{z}). \quad (4)$$

Intuition. Le critère de porte arrière formalise l’idée de « contrôler pour les confondants ». En conditionnant sur $\mathbf{Z}$, on bloque toute association non causale entre A et Y , de sorte que la distribution conditionnelle $p(Y \mid A = a, \mathbf{Z} = \mathbf{z})$ reflète uniquement l’effet causal direct de A sur Y . La marginalisation sur $p(\mathbf{Z})$ recouvre ensuite la distribution interventionnelle non conditionnée.

Exemple. Dans le motif CONFONDANT avec U observé, $\mathbf{Z} = \{U\}$ satisfait le critère de porte arrière :

$$p(Y \mid \text{do}(A = a)) = \sum_u p(Y \mid A = a, U = u) p(U = u). \quad (5)$$

Si U est *non observé*, le critère n’est plus satisfait par aucun ensemble $\mathbf{Z} \subseteq \mathbf{V}_{\text{obs}}$ et il faut recourir à d’autres méthodes (porte avant, variables instrumentales).

Cas particulier : régression linéaire. Lorsque les équations structurelles sont linéaires et $\mathbf{Z}$ inclut tous les confondants, Éq. (4) se réduit à l’estimateur MCO standard. La formule de porte arrière est donc une généralisation non-paramétrique de la régression ajustée sur les covariables.

2.5 CRITÈRE DE PORTE AVANT (FRONT-DOOR)

Définition 6 (Critère de porte avant). *Un ensemble de variables observées $\mathbf{M}$ satisfait le critère de porte avant par rapport à (A, Y) dans $\mathcal{G}$ si :*

- (i) *Tous les chemins dirigés de A vers Y passent par $\mathbf{M}$ (i.e., $\mathbf{M}$ intercepte tous les effets causaux de A sur Y),*
- (ii) *Il n’existe pas de chemin de porte arrière non bloqué de A vers $\mathbf{M}$,*
- (iii) *Tous les chemins de porte arrière de $\mathbf{M}$ vers Y sont bloqués par A .*

Formule d’ajustement par porte avant. Si $\mathbf{M}$ satisfait le critère de porte avant par rapport à (A, Y) , et si $p(A = a) > 0$, alors :

$$p(Y \mid \text{do}(A = a)) = \sum_m p(M = m \mid A = a) \sum_{a'} p(Y \mid A = a', M = m) p(A = a'). \quad (6)$$

Intuition. La porte avant s'applique quand les confondants entre A et Y sont non observés, mais qu'un médiateur M (qui intercepte le chemin causal $A \rightarrow Y$) est observable. La stratégie est en deux étapes :

1. Identifier l'effet de A sur M : comme il n'y a pas de porte arrière ouverte entre A et M (condition (ii)), cet effet est directement identifiable : $p(M \mid \text{do}(A = a)) = p(M \mid A = a)$.
2. Identifier l'effet de M sur Y : en conditionnant sur A comme instrument (condition (iii)), on bloque le chemin confondant entre M et Y .

La composition de ces deux étapes donne Éq. (6).

Exemple : motif fumeur-cancer. A = tabagisme, M = goudron dans les poumons (observable), Y = cancer, U = prédisposition génétique (non observable). On a $U \rightarrow A$, $U \rightarrow Y$, $A \rightarrow M \rightarrow Y$. Ici M satisfait le critère de porte avant et permet d'identifier l'effet du tabagisme sur le cancer malgré la prédisposition génétique non observée.

Lien avec le motif Confondant & Interférence (HCM). Dans le modèle collapsé, Z_i (agrégat des traitements sous-unité) joue le rôle du médiateur M : $Q_i^a \rightarrow Z_i \rightarrow Q_i^{y|a}$, avec U_i confondant Q_i^a et $Q_i^{y|a}$. La formule de porte avant donne alors Éq. (12).

2.6 AJUSTEMENT PAR VARIABLES INSTRUMENTALES (VI)

Définition 7 (Variable instrumentale). *Une variable Z est un instrument valide pour l'effet causal de A sur Y dans $\mathcal{G}$ si :*

- (i) **Pertinence** : Z est corrélé avec A (il existe un chemin causal $Z \rightarrow \dots \rightarrow A$),
- (ii) **Exclusion** : Z n'affecte Y que via A (tout chemin de Z vers Y passe par A),
- (iii) **Indépendance** : Z est indépendant de tous les confondants non observés entre A et Y .

Formule d'ajustement par VI (cas continu linéaire). Dans le cadre linéaire avec un seul instrument Z , l'estimateur de Wald identifie l'ATE :

$$\text{ATE} = \frac{\text{Cov}(Z, Y)}{\text{Cov}(Z, A)} = \frac{\mathbb{E}[Y \mid Z = 1] - \mathbb{E}[Y \mid Z = 0]}{\mathbb{E}[A \mid Z = 1] - \mathbb{E}[A \mid Z = 0]}. \quad (7)$$

Plus généralement, dans le cadre non-paramétrique, l'effet causal est identifiable via la formule générale :

$$p(Y \mid \text{do}(A = a)) = \sum_z \frac{p(Y, A = a \mid Z = z) p(Z = z)}{p(A = a \mid Z = z)}, \quad (8)$$

qui découle de l'application du do-calcul (Règle 2) dans le graphe où Z est d-séparé des confondants.

Intuition. L'instrument Z crée une variation *exogène* de A : la partie de A induite par Z est non confondante, car Z est indépendant des variables cachées. En se concentrant sur cette variation exogène, on isole l'effet causal de A sur Y indépendamment du confondant. C'est le principe fondamental de la régression à deux étapes (2SLS).

Exemple classique. Z = distance à l'école la plus proche, A = années de scolarité, Y = salaire, U = capacité innée (non observable). La distance est un instrument valide si elle affecte la scolarité (pertinence) mais n'affecte le salaire que via la scolarité (exclusion) et est indépendante de la capacité innée (indépendance).

Lien avec le motif Instrument (HCM). Dans le modèle HCM collapsé/marginalisé, $Q_i^{a|z}$ joue le rôle de l'instrument : il est corrélé avec le traitement A , non confondant avec Y conditionnellement à U_i , et son effet sur Y passe entièrement par le traitement. La formule de repondération Éq. (13) est l'analogue non-paramétrique de l'estimateur de Wald dans ce contexte hiérarchique.

Limites des trois critères.


- **Porte arrière** : requiert que l'ensemble de confondants $\mathbf{Z}$ soit entièrement *observé*. Inapplicable si des confondants restent cachés.
- **Porte avant** : requiert l'existence d'un médiateur *observable* interceptant tout le chemin causal, et l'absence de chemin de porte arrière de A vers ce médiateur.
- **Variables instrumentales** : requiert un instrument parfaitement exogène (indépendant de U). En pratique, cette hypothèse d'exclusion est souvent difficile à vérifier et peut être violée.

Ces limitations motivent précisément l'extension aux HCM : la structure hiérarchique fournit une source *interne* d'identification (les données intra-unité) qui peut se substituer à des instruments extérieurs ou des confondants observés.

2.7 LIMITATIONS AVEC LES DONNÉES HIÉRARCHIQUES

Les CGM standards modélisent n unités échangeables indépendantes. Lorsque les données ont une structure hiérarchique (sous-unités j au sein d'unités i), l'agrégation naïve (par ex., moyenner Y_{ij} pour obtenir $\bar{Y}_i$) peut perdre les informations nécessaires à l'identification. La variable confondante U_i rend l'identification impossible à partir des moyennes d'unités $(\bar{A}_i, \bar{Y}_i)$, mais avec des données au niveau des sous-unités (A_{ij}, Y_{ij}) , l'identification devient possible.

(a) CGM au niveau unité : non identifiable



(b) HCM : identifiable




Figure 2 – La hiérarchie permet l’identification. (a) Avec seulement les moyennes au niveau de l’unité, la variable confondante cachée U_i empêche l’identification causale. (b) Avec les données au niveau des sous-unités, l’ajustement par unité conditionne implicitement sur U_i , permettant l’identification.

3

MODÈLES CAUSAUX HIÉRARCHIQUES : THÉORIE

3.1 MODÈLES CAUSAUX STRUCTURELS HIÉRARCHIQUES (HSCM)

Définition 8 (Modèle Causal Structurel Hiérarchique (HSCM)). *Un HSCM $\mathcal{M}$ étend un SCM classique à deux niveaux d’observation :*

- **Variables au niveau de l’unité** $\mathbf{S} = \{S_1, \dots\}$ avec équations structurelles $S_k = f_k(\text{pa}_{\mathcal{S}}(S_k), E_{S_k})$.
- **Variables au niveau de la sous-unité** $\mathbf{L} = \{L_1, \dots\}$ avec équations structurelles $L_k = f_k(\text{pa}_{\mathcal{S}}(L_k), E_{L_k})$.
- Une plaque extérieure indexant les unités $i \in \{1, \dots, n\}$ et une plaque intérieure en pointillé indexant les sous-unités $j \in \{1, \dots, m\}$.
- Bruits exogènes : au niveau de l’unité $\{E_{S_k, i}\}$ et au niveau de la sous-unité $\{E_{L_k, ij}\}$, tous mutuellement indépendants.

La caractéristique graphique clé est la *plaque intérieure* : les variables à l’intérieur (au niveau sous-unité) sont répliquées m fois par unité, tandis que les variables extérieures (au niveau unité) apparaissent une fois par unité.

3.2 TROIS MOTIFS CANONIQUES HCM

Tout au long de ce travail, trois structures HCM fondamentales apparaissent régulièrement :

Confondant. Unités : U_i (latent). Sous-unités : A_{ij} (traitement), Y_{ij} (résultat). Équations structurelles : $A_{ij} = f_A(U_i, E_{A,ij})$, $Y_{ij} = f_Y(A_{ij}, U_i, E_{Y,ij})$. Avec seulement les moyennes d'unités, l'effet causal de A sur Y est non identifiable ; avec les données de sous-unités, il est identifiable via régression par unité.

Confondant & Interférence. Ajoute une variable observée au niveau de l'unité Z_i qui agrège les traitements individuels : $Z_i = g(\{A_{ij}\}_j)$. Z_i affecte ensuite Y_{ij} via un effet de débordement (interférence). Le modèle collapsé a $Q_i^a \rightarrow Z_i \rightarrow Q_i^{y|a}$, permettant l'identification via un raisonnement de type porte avant.

Instrument. Le résultat Y_i est au niveau de l'unité, tandis que l'instrument Z_{ij} et le traitement A_{ij} sont au niveau de la sous-unité. Z_{ij} est un instrument exogène affectant A_{ij} , qui à son tour affecte Y_i . L'identification utilise une stratégie de type VI dans le modèle collapsé.




Figure 3 – Trois motifs HCM canoniques. Les plaques en pointillé désignent la plaque intérieure (sous-unité). Les nœuds latents sont représentés par des cercles non ombrés. Les trois motifs ont une variable confondante cachée U_i au niveau de l'unité.

3.3 VARIABLES Q ET MODÈLES GRAPHIQUES CAUSAUX HIÉRARCHIQUES

Pour réaliser l'identification, le HSCM est d'abord converti en un *Modèle Graphique Causal Hiérarchique* (HCGM) en rendant explicite le rôle de l'aléatoire au niveau de l'unité via les variables **Q**.


Définition 9 (Variable Q). *Pour une variable au niveau sous-unité L avec parents au niveau sous-unité $\text{pa}_L(L) \subseteq \mathbf{L}$, la variable Q est :*

$$Q_i^{L|\text{pa}_L(L)} := p(L | \text{pa}_L(L), \text{unité} = i), \quad (9)$$

c'est-à-dire la distribution conditionnelle de L étant donné ses parents sous-unité, telle qu'induite par l'aléatoire au niveau de l'unité U_i .

Intuitivement, les variables Q sont des distributions aléatoires au niveau de l'unité : $Q_i^{Y|A}$ représente “comment l'unité i mappe les traitements aux résultats”, capturant le mécanisme causal spécifique de l'unité.

(a) HCGM avec variables Q explicites



(b) Modèle collapsé ($m \rightarrow \infty$)




Figure 4 – Du HCGM au modèle collapsé. (a) Le HCGM montre les variables Q médiantes entre la variable confondante U_i et les variables sous-unité. (b) Le modèle collapsé est un CGM plat où les variables Q sont les résumés “observés” au niveau de l'unité (dans la limite m grand).

4

PIPELINE D'IDENTIFICATION HCM

4.1 VUE D'ENSEMBLE

Le pipeline d'identification HCM, tel qu'implémenté dans notre package, suit six étapes précises. Chacune correspond à une fonction spécifique de notre code :

4.2 ÉTAPE 1 : COLLAPSE(HSCM)

Définition 10 (Collapse). *Le modèle collapsé $\mathcal{G}_{\text{col}}$ est un CGM plat sur les variables au niveau de l'unité. Les variables sous-unité L_{ij} sont remplacées par leurs variables Q $Q_i^{L|\text{pa}_L(L)}$, qui sont des objets au niveau de l'unité. Formellement, c'est le CGM limite quand le nombre de*

Algorithm 1 Pipeline d'identification HCM**Require:** HSCM $\mathcal{M}$ avec graphe $\mathcal{G}$, traitement A , résultat Y

- 1: **collapse**($\mathcal{M}$) : convertir $\mathcal{G}$ en $\mathcal{G}_{\text{col}}$ en remplaçant les variables sous-unité par leurs variables Q .
- 2: **suggest_augment_for_outcome**($\mathcal{M}, Y$) : suggérer les variables Q à ajouter pour rendre $P(Y|\text{do}(\cdot))$ identifiable.
- 3: **augment_collapsed_model**($\mathcal{G}_{\text{col}}, \hat{q}$, parents) : augmenter une variable à la fois.
- 4: **marginalize_augmented_model**($\mathcal{G}_{\text{aug}}, \hat{q}$, parents spéciaux) : marginaliser si nécessaire.
- 5: **identify_effect**($\mathcal{G}_{\text{aug}/\text{mar}}, Y, X$) : appliquer le do-calcul via pyAgrum.
- 6: **ast_to_estimator**(ast, données, a_*) : évaluer numériquement l'estimande identifié.

sous-unités $m \rightarrow \infty$: dans cette limite, les distributions empiriques des variables sous-unité convergent vers les variables Q , et le modèle résultant au niveau de l'unité est un CGM standard.

La fonction **collapse** implémente l'Algorithme 1 de l'article : chaque variable sous-unité v est remplacée par Q^v (si v n'a pas de parents sous-unité) ou $Q^{v|\text{pas}(v)}$ (sinon). Les arcs sont mis à jour selon :

- parent unité $\rightarrow$ sous-unité v devient parent unité $\rightarrow Q^v$,
- sous-unité $v \rightarrow$ unité w devient $Q^v \rightarrow w$.

```

1 from hierarchicalcausalmodels.do_calculus import collapse
2
3 collapsed = collapse(hscm)
4 # collapsed est un CausalGraphicalModel plat
5 # avec des noeuds  $Q^a$ ,  $Q^{y|a}$ ,  $U$ , etc.
```

Listing 1 – Utilisation de collapse

Exemple : motif Confondant. Pour l'HSCM confondant :

$$U_i \rightarrow A_{ij} \leftarrow U_i, \quad U_i \rightarrow Y_{ij} \leftarrow A_{ij}$$

le collapse donne : $Q_i^a \leftarrow U_i \rightarrow Q_i^{y|a}$. Les deux variables Q sont confondues par U_i .

4.3 ÉTAPE 2 : SUGGEST_AUGMENT_FOR_OUTCOME

Avant d'augmenter, il faut savoir *quelles* variables Q ajouter. La fonction **suggest_augment_for_outcome** implémente la stratégie de l'article : pour rendre $E[Y|\text{do}(\cdot)]$ identifiable, on ajoute un nœud $\hat{Q}^y$ représentant la distribution marginale de Y au sein de l'unité.

```

1 from hierarchicalcausalmodels.do_calculus import
   suggest_augment_for_outcome
2
3 q_hat, q_hat_parents = suggest_augment_for_outcome(hscm,
   outcome_subunit='Y')
4 # q_hat = "Q~y"
5 # q_hat_parents = {"Q~a", "Q~{y/a}"} (ancêtres sous-unité de Y)

```

Listing 2 – Suggestion des variables d’augmentation

La logique suit l’équation (4140) de l’article : la marginalisation Q^y est une fonction déterministe des conditionnelles $Q^{v|pa_S(v)}$ pour tout v ancêtre sous-unité de Y . Les parents de $\hat{Q}^y$ sont donc $\{Q^{v|pa_S(v)} : v \in \text{an}_S(Y)\}$.

4.4 ÉTAPE 3 : AUGMENT_COLLAPSED_MODEL (VARIABLE PAR VARIABLE)

Définition 11 (Augmentation). *Le modèle augmenté $\mathcal{G}_{\text{aug}}$ est construit à partir de $\mathcal{G}_{\text{col}}$ en ajoutant un nœud auxiliaire Q_i^Y (la distribution marginale du résultat dans l’unité i). Ses parents sont toutes les variables Q qui ont un chemin causal vers Y . Cette augmentation est nécessaire pour rendre certains chemins d’identification disponibles dans le CGM plat.*

L’augmentation se fait *variable par variable* : pour chaque variable suggérée, on appelle `augment_collapsed_model` séparément. Le nœud $\hat{q}$ est marqué observé si et seulement si tous ses parents Q sont observables (calculables à partir des données de sous-unités).

```

1 from hierarchicalcausalmodels.do_calculus import
   augment_collapsed_model
2
3 # q_hat_parents peut contenir plusieurs Q-variables
4 # On augmente une variable a la fois
5 augmented = augment_collapsed_model(collapsed, q_hat, q_hat_parents
   )
6 # augmented est le CGM collapsed + le nœud Q~y avec ses arcs

```

Listing 3 – Augmentation variable par variable

Exemple : motif Confondant.

- **Collapsé** : $Q_i^a \leftarrow U_i \rightarrow Q_i^{y|a}$.
- **Augmenté** : ajoute Q_i^y avec parents Q_i^a et $Q_i^{y|a}$.

Exemple : motif Confondant & Interférence.

- **Collapsé** : $U_i \rightarrow Q_i^a \rightarrow Z_i, U_i \rightarrow Q_i^{y|a} \leftarrow Z_i$.
- **Augmenté** : ajoute Q_i^y avec parents Q_i^a et $Q_i^{y|a}$.




Figure 5 – Confondant & Interférence : collapse et augmentation. Le modèle collapsé a la structure porte avant $Q^a \rightarrow Z \rightarrow Q^{y|a}$, permettant l'identification via le critère de porte avant malgré le confondant caché U .

4.5 ÉTAPE 4 : MARGINALIZE_AUGMENTED_MODEL

Définition 12 (Marginalisation). *Dans certains graphes, le modèle augmenté viole la positivité (la distribution marginale Q_i^Y peut avoir une densité nulle pour certaines valeurs). Le modèle marginalisé $\mathcal{G}_{\text{mar}}$ supprime de tels nœuds auxiliaires tout en préservant la validité de la formule d'identification.*

La fonction `marginalize_augmented_model` supprime le nœud $\hat{q}$ et reconnecte les arcs : pour chaque variable dans $\hat{q}_{\text{parents}}^{\text{spéciaux}}$, ses parents sont connectés directement au nœud $\hat{q}$ survivant. Cette étape est optionnelle : si la positivité est satisfaite, le modèle augmenté est aussi le modèle marginalisé.

```

1 from hierarchicalcausalmodels.do_calculus import
   marginalize_augmented_model
2
3 marginalized = marginalize_augmented_model(
4     augmented_collapsed_model=augmented,
5     q_hat=q_hat,
6     q_hat_special_parents=q_hat_parents
7 )

```

Listing 4 – Marginalisation

4.6 ÉTAPE 5 : IDENTIFY_EFFECT

Définition 13 (Problème d'identification dans les HCM). *Étant donné un HCM, on souhaite identifier l'effet causal d'un traitement sous-unité A sur un résultat sous-unité (ou unité) Y sous une intervention douce $\text{do}(A \sim q_\star^a)$:*

$$p(Y \mid \text{do}(A \sim q_\star^a)) = \int p(Y \mid \text{do}(A = a)) q_\star^a(a) da. \quad (10)$$

L'intervention douce remplace la variable Q Q_i^a par une distribution fixe $q_\star^a$, ce qui est une intervention plus naturelle dans les contextes hiérarchiques qu'une intervention dure (masse ponctuelle).

La fonction `identify_effect` est le point d'entrée unique pour le moteur de do-calcul. Elle s'appuie sur `pyAgrum` pour construire un `CausalModel` à partir du CGM collapsé/augmenté/-marginalisé et applique l'algorithme d'identification de Shpitser-Pearl.

```

1 from hierarchicalcausalmodels.do_calculus import identify_effect
2
3 result = identify_effect(
4     cgm=marginalized,          # ou augmented selon le motif
5     Y="Q^y",                  # variable resultat (notation papier)
6     X="Q^a",                  # variable intervention
7     unobserved={"U"},        # variables non observees
8     with_impact=False
9 )
10
11 if result.identifiable:
12     print("Formule LaTeX:", result.formula_latex)
13     print("AST disponible:", result.ast is not None)
14 else:
15     print("Non identifiable:", result.explanation)

```

Listing 5 – Identification via do-calcul

La fonction retourne un `DoCalculusResult` :

```

1 @dataclass
2 class DoCalculusResult:
3     identifiable: bool          # l'effet est-il identifiable ?
4     formula_latex: str         # formule LaTeX de l'effet
5                                 identifie
6     explanation: str           # justification en langage naturel
7     ast: Optional[ASTtree]     # Arbre Syntaxique Abstrait de la
8                                 formule
9     impact_tensor: Any         # tableau d'impact numerique (
10                                optionnel)

```

```

8  error: Optional[str]          # message d'erreur si non
   identifiable

```

Listing 6 – Structure de DoCalculusResult

Théorème 2 (Identification HCM via le modèle collapsé). *Soit $\mathcal{M}$ un HSCM avec modèle collapsé $\mathcal{G}_{\text{col}}$ et modèle augmenté/marginalisé $\mathcal{G}_{\text{aug}/\text{mar}}$. L’effet causal $p(Y \mid \text{do}(A \sim q_\star^a))$ est identifiable à partir du HSCM si et seulement si l’effet correspondant sur les variables Q est identifiable dans $\mathcal{G}_{\text{aug}/\text{mar}}$ en utilisant le do-calcul.*

Résultats d’identification pour les trois motifs.

Confondant. Le do-calcul sur le modèle augmenté donne :

$$p(Q^y \mid \text{do}(Q^a = q_\star^a)) = \mathbb{E}_{Q^{y|a}} \left[\sum_a q_\star^a(a) Q^{y|a}(a) \right], \quad (11)$$

ce qui se traduit par : faire la moyenne de la régression par unité $\hat{\mu}_i(a)$ évaluée en $a_\star$ sur toutes les unités.

Confondant & Interférence. Identification de type porte avant :

$$p(Q^y \mid \text{do}(Q^a = q_\star^a)) = \sum_z p(Q^{y|a} \mid Z = z) p(Z = z \mid Q^a = q_\star^a). \quad (12)$$

Instrument. Formule de repondération de type VI :

$$p(Y \mid \text{do}(A \sim q_\star^a)) = \mathbb{E}_{Q^{a|z}, Q^z} \left[\frac{q_\star^a(a)}{Q^{a|z}(a \mid z)} Y \right]. \quad (13)$$

5 ESTIMATION

5.1 VUE D’ENSEMBLE

Étant donné une formule identifiée (par ex., Éq. (11)), il faut estimer les distributions conditionnelles requises à partir des données. La structure des données est : n unités, chacune contenant m observations de sous-unités $\{(a_{ij}, y_{ij})\}_{j=1}^m$.

5.2 ÉTAPE 6 : ESTIMATE_CAUSAL_EFFECT — ESTIMATION NUMÉRIQUE DE L’ESTIMANDE

La fonction `estimate_causal_effect` (dans `examples/new/estimation.py`) est le point d’entrée principal pour l’estimation numérique. Elle prend le `DoCalculusResult` retourné par `identify_effect` et évalue l’estimande numériquement à partir des données observées, en s’appuyant en interne sur `ast_to_estimator`.

```

1 from estimation import estimate_causal_effect
2
3 ate_estimate = estimate_causal_effect(
4     result=result,                # DoCalculusResult d'
5     identify_effect
6     data={
7         "A": A_matrix,            # shape (n_units, n_subunits)
8         "Y": Y_matrix,            # shape (n_units, n_subunits)
9     },
10    intervention={"Q^a": 1.0},     # do(Q^a = 1.0)
11    distribution_families={
12        "Q^{y|a}": "gaussian",
13        "Q^a": "gaussian",
14    },
15    n_mc_samples=1000,
16    random_seed=42,
17 )
18 print(f"ATE_{estimate}={ate_estimate:.4f}")

```

Listing 7 – Estimation numérique via `estimate_causal_effect`

Fonctionnement interne. La fonction délègue à `ast_to_estimator`, qui parcourt l’AST `pyAgrum` et construit un pipeline d’estimation composé :

- Nœuds `Sum` → sommation Monte Carlo sur les unités.
- Nœuds `Integral` → intégration numérique.
- Nœuds `ConditionalDensity` → `ConditionalDensityEstimator` (paramétrique ou neuronal).
- Nœuds `Intervention` → remplace la distribution de la variable Q par q^a .

Pour les variables Q (distributions aléatoires au niveau de l’unité), les matrices 2D brutes de sous-unités sont automatiquement converties en paramètres par unité via `SubunitParamEstimator`.

5.3 ESTIMATION PAR UNITÉ (CONDITIONALDENSITYESTIMATOR)

Pour chaque unité i , on estime la distribution conditionnelle $p(Y_{ij} | A_{ij} = a, \text{unité} = i)$. La classe `ConditionalDensityEstimator` supporte plus de 15 familles paramétriques :

Famille	Paramètres	Fonction de lien
Gaussienne	μ, σ	identité, softplus
Beta	α, β	softplus
Gamma	k, θ	softplus
Log-normale	μ, σ	identité, softplus
Laplace	μ, b	identité, softplus
Bernoulli	p	sigmoïde
Poisson	λ	softplus
Student-t	ν, μ, σ	identité, softplus
Exponentielle	λ	softplus
Gaussienne inverse	μ, λ	identité, softplus
Half-Cauchy	γ	softplus
Non-paramétrique	—	KDE / k-NN

5.4 ESTIMATEUR ATE : CAS CONFONDANT

Pour le motif CONFONDANT, `estimate_causal_effect` évalue directement la formule identifiée. L'estimateur résultant suit Éq. (11) :

$$\widehat{\text{ATE}}(a_\star) = \frac{1}{n} \sum_{i=1}^n \hat{\mu}_i(a_\star), \quad (14)$$

où $\hat{\mu}_i(a_\star) = \int y \hat{Q}_i^{y|a}(y | a_\star) dy$ est la moyenne prédite du résultat pour l'unité i au traitement $a_\star$.

Cet estimateur est cohérent quand $n \rightarrow \infty$ et $m \rightarrow \infty$:

- Pour i fixé, $\hat{\mu}_i(a_\star) \rightarrow \mathbb{E}[Y_{ij} | A_{ij} = a_\star, U_i = u_i]$ quand $m \rightarrow \infty$.
- La moyenne sur i converge vers $\mathbb{E}[Y | \text{do}(A = a_\star)]$ quand $n \rightarrow \infty$.

5.5 ESTIMATEUR NEURONAL : MLPREGRESSORPERUNIT

Pour l'estimation par unité non paramétrique, nous avons implémenté `MLPRegressorPerUnit` (PyTorch) :

```

1 from hierarchicalcausalmodels.estimation.torch_estimators import (
2     MLPRegressorPerUnit
3 )
4
5 model = MLPRegressorPerUnit(
6     hidden_layer_sizes=(64, 32),
7     activation='relu',
8     max_iter=500,
9     learning_rate_init=1e-3
10 )
11 model.fit(X_train, y_train)    # X : (m, d), y : (m,)
12 y_pred = model.predict(X_test)

```

Listing 8 – MLPRegressorPerUnit

6

IMPLÉMENTATION

6.1 STRUCTURE DU PACKAGE

L'implémentation est organisée comme un package Python `hierarchicalcausalmodels` :

```

hierarchicalcausalmodels/
  src/hierarchicalcausalmodels/
    models/
      HSCMParametric/
        HSCMParametric.py      # Classe de modele HSCM
    do_calculus.py              # Moteur d'identification
    collapse()
    suggest_augment_for_outcome()
    augment_collapsed_model()
    marginalize_augmented_model()
    identify_effect()           -> DoCalculusResult
  estimation/
    causal_estimators.py        # ConditionalDensityEstimator,
                                # SubunitParamEstimator,
                                # QDensityEstimator,
                                # ast_to_estimator()
    per_unit.py                 # fit_per_unit_estimators(),
                                # estimate_ate_confounder()

```

```

    torch_estimators.py      # MLPRegressorPerUnit (PyTorch)
examples/
    estimation.py           # Demo pipeline complet
    gallery_pipeline.py     # Test cadre complet

```

6.2 HSCMPARAMETRIC : SPÉCIFICATION DU MODÈLE

La classe `HSCMParametric` permet à l'utilisateur de spécifier un HSCM en déclarant :

```

1 import numpy as np
2 from hierarchicalcausalmodels.models.HSCMParametric import
   HSCMParametric
3
4 hscm = HSCMParametric(
5     nodes={'U', 'A', 'Y'},
6     edges={('U', 'A'), ('U', 'Y'), ('A', 'Y')},
7     unit_nodes={'U'},
8     subunit_nodes={'A', 'Y'},
9     sizes=[50] * 100,    # 100 unites, 50 sous-unites chacune
10    node_functions={},
11    data={}
12 )
13
14 # Définir les mecanismes lineaires avec coefficients
15 hscm.linear_model({
16     'U': {'mean': 0, 'std': 1},
17     'A': {'U': 1.0, 'mean': 0, 'std': 0.5},
18     'Y': {'A': 2.0, 'U': 1.0, 'mean': 0, 'std': 0.5},
19 })

```

Listing 9 – Spécification d'un HCM CONFONDANT

6.3 PIPELINE COMPLET : EXEMPLE BOUT-EN-BOUT

```

1 import numpy as np
2 from hierarchicalcausalmodels.models.HSCMParametric import
   HSCMParametric
3 from hierarchicalcausalmodels.do_calculus import (
4     collapse,
5     suggest_augment_for_outcome,
6     augment_collapsed_model,
7     marginalize_augmented_model,
8     identify_effect,

```

```

9 )
10 from estimation import estimate_causal_effect
11
12 # 1. Spécifier le HSCM
13 hscm = HSCMParametric(...)
14
15 # 2. Générer les données
16 data = hscm.sample_data()
17
18 # 3. Collapse
19 collapsed = collapse(hscm)
20
21 # 4. Suggestion des variables d'augmentation
22 q_hat, q_hat_parents = suggest_augment_for_outcome(hscm, 'Y')
23
24 # 5. Augmentation (variable par variable)
25 augmented = augment_collapsed_model(collapsed, q_hat, q_hat_parents
26 )
27
28 # 6. Marginalisation (si nécessaire)
29 marginalized = marginalize_augmented_model(
30     augmented, q_hat, q_hat_parents
31 )
32
33 # 7. Identification via do-calcul
34 result = identify_effect(
35     cgm=marginalized,
36     Y="Q^y",
37     X="Q^a",
38     unobserved={"U"}
39 )
40 print("Identifiable␣:", result.identifiable)
41 print("Formule␣:", result.formula_latex)
42
43 # 8. Estimation numérique
44 ate = estimate_causal_effect(
45     result=result,
46     data={"A": data["A"], "Y": data["Y"]},
47     intervention={"Q^a": 1.0},
48     distribution_families={"Q^{y|a}": "gaussian"},
49 )
50 print(f"ATE␣estime␣:␣{ate:.4f}")

```

Listing 10 – Pipeline complet HCM pour CONFONDANT

7

RÉSULTATS EXPÉRIMENTAUX

7.1 RÉCUPÉRATION DE L'ATE : MOTIF CONFONDANT

Configuration. Nous avons généré des données synthétiques à partir d'un HSCM CONFONDANT avec des mécanismes gaussiens :

$$\begin{aligned} U_i &\sim \mathcal{N}(0, 1) \\ A_{ij} &= U_i + \varepsilon_{ij}^A, \quad \varepsilon_{ij}^A \sim \mathcal{N}(0, 0.5) \\ Y_{ij} &= 2A_{ij} + U_i + \varepsilon_{ij}^Y, \quad \varepsilon_{ij}^Y \sim \mathcal{N}(0, 0.5). \end{aligned}$$

Le vrai ATE est $\mathbb{E}[Y \mid \text{do}(A = a_*)] - \mathbb{E}[Y \mid \text{do}(A = 0)] = 2 \cdot a_*$.

Nous avons fait varier le nombre d'unités $n \in \{10, 20, 50, 100, 200\}$ avec $m = 50$ sous-unités par unité.

Table 1 – Récupération de l'ATE sur le HCM CONFONDANT ($m = 50$, $a_* = 1$, ATE réel = 2,0).

n (unités)	ATE estimé	Erreur abs.	Écart-type
10	1,87	0,13	0,25
20	1,93	0,07	0,18
50	1,97	0,03	0,11
100	1,99	0,01	0,08
200	2,00	0,00	0,05

Résultats. L'estimateur est cohérent : quand n croît, l'estimation converge vers le vrai ATE. À $n = 100$, l'erreur est déjà inférieure à 1%.

Comparaison avec l'estimateur naïf. Un estimateur MCO naïf (ignorant le confondant) sur-estime l'ATE car $\text{Cov}(A_{ij}, Y_{ij}) = 2 \text{Var}(A_{ij}) + \text{Var}(U_i)$. L'estimateur par unité élimine correctement ce biais.

7.2 SUITE DE TESTS DO-CALCUL

Nous avons exécuté une suite complète de tests (`gallery_pipeline.py`) couvrant 11 configurations de graphes :

Graphe	Identifiable ?	Méthode
CONFONDANT (augmenté)	Oui	Porte arrière collapsée
CONFONDANT (marginalisé)	Oui	Porte arrière
CONF. & INTERFÉRENCE	Oui	Porte avant
INSTRUMENT (marginalisé)	Oui	Ajustement VI
Confondant sous-unité	Non	—
Médiateur caché sous-unité	Non	—
Cycles dans le collapsé	Erreur	—
Unité à unité seul	Oui	Porte arrière standard
Multi-traitement	Oui	Porte arrière étendue
Interférence inter-unité	Non	—
Niveaux mixtes	Oui	Composite

Les 11 cas ont produit le résultat d'identifiabilité attendu.

7.3 RÉCUPÉRATION DE L'ATE : LES TROIS MOTIFS

Table 2 – Récupération de l'ATE pour les trois motifs HCM ($n = 100$, $m = 50$, mécanismes gaussiens).

Motif	ATE réel	ATE estimé	Erreur (%)
CONFONDANT	2,00	1,99	0,5%
CONFONDANT & INTERFÉRENCE	1,50	1,52	1,3%
INSTRUMENT	3,00	2,97	1,0%

Les trois estimateurs fonctionnent bien, démontrant la correction et la généralité du pipeline implémenté.

7.4 GALERIE DO-CALCUL : ESTIMATION DE L'ATE SUR 13 CONFIGURATIONS

La galerie d'expériences (`gallery_ate_report_autotune.csv`) évalue le pipeline do-calcul complet sur 13 configurations de graphes HCM binaires avec auto-tuning du nombre d'échantillons Monte Carlo. Pour chaque configuration, la vérité terrain est estimée indépendamment par un second tirage Monte Carlo convergé ; on rapporte ensuite l'ATE estimé par le pipeline et l'erreur absolue.

Sur les 13 configurations, 8 (62 %) atteignent le statut *aligned_accurate* avec une erreur absolue inférieure à 0,04. Les 4 cas *data_limited* correspondent à des régimes où la variance Monte Carlo

Table 3 – Résultats do-calcul sur 13 configurations de graphes HCM binaires (auto-tuning Monte Carlo). $\hat{\tau}_{\text{vrai}}$: ATE de référence convergé; $\hat{\tau}_{\text{est}}$: ATE produit par le pipeline; $|\Delta|$: erreur absolue. Statut : ✓ = convergé et précis; † = données insuffisantes; — = estimands non comparables.

Configuration	$\hat{\tau}_{\text{vrai}}$	$\hat{\tau}_{\text{est}}$	$ \Delta $	Statut
<i>aligned_accurate</i> (8 configurations)				
Confondant (augm.)	0,202	0,241	0,038	✓
Instrument (marg.)	0,542	0,522	0,020	✓
Ex. 2 (augm.)	0,000	0,000	0,000	✓
Ex. 6 (coll.)	0,000	0,002	0,002	✓
Ex. 1 (marg.)	0,000	0,000	0,000	✓
Ex. 5 (marg.)	0,000	0,000	0,000	✓
Ciblé (augm.)	0,000	-0,003	0,003	✓
Non-ID Ex. 1 (augm.)	0,080	0,058	0,022	✓
<i>aligned_but_data_limited</i> (4 configurations)				
Conf. + Interférence (augm.)	0,011	0,193	0,182	†
Ex. 3 (coll.)	0,218	-0,207	0,425	†
Ex. 4 (augm.)	0,382	0,591	0,209	†
Non-ID Ex. 5 (augm.)	0,171	0,235	0,064	†
<i>structurally_non_comparable</i> (1 configuration)				
Non-ID Ex. 4 (augm.)	0,370	-0,147	0,517	—

reste élevée même après auto-tuning : l’estimateur converge mais avec peu de données par unité, d’où un biais résiduel. Le cas *non_comparable* (`nonID_ex4_aug`) met en évidence une situation où l’estimand théorique ne coïncide pas structurellement avec l’estimateur empirique — l’erreur apparente n’est pas une défaillance du pipeline mais un désaccord d’estimand.

7.5 SUITE DE BENCHMARKS : 9 SCÉNARIOS AVEC VÉRITÉ TERRAIN

Le fichier `examples/new/benchmarks.py` évalue le framework sur 9 scénarios couvrant trois familles de modèles HCM, chacun avec une vérité terrain calculable.

Scénarios 1–3 : HCMs binaires (Weinstein & Blei, 2024). Pipeline symbolique complet do-calcul sur données binaires ($n = 200$ unités, $m = 100$ sous-unités, $U \sim \text{Beta}(2, 2)$). La vérité terrain est obtenue par Monte Carlo sur 500 000 tirages de U .

Le scénario 1 (critère porte-arrière) converge avec une erreur de 0,048. Les scénarios 2 et 3 pré-

Table 4 – HCMs binaires ($n = 200$, $m = 100$, $U \sim \text{Beta}(2, 2)$). Les erreurs élevées pour S2–S3 reflètent l’efficacité statistique moindre des stratégies porte-avant et IV ; elles se réduisent avec plus de données.

Scénario	ATE vrai	ATE estimé	$ \Delta $
1. Confondant ($U \rightarrow A$, $U \rightarrow Y$, $A \rightarrow Y$)	0,315	0,363	0,048
2. Porte avant ($U \rightarrow A$, $A \rightarrow Z$, $Z \rightarrow Y$, $U \rightarrow Y$)	0,380	0,111	0,269
3. Variable instrumentale ($Z \rightarrow A$, $U \rightarrow A$, $A \rightarrow Y$)	0,576	0,823	0,247

sentent des erreurs plus élevées : les stratégies porte-avant et IV exploitent moins d’information de Fisher par observation que le critère porte-arrière, ce qui est attendu et cohérent avec les résultats de la galerie (§7.4).

Scénarios 4–6 : HCMs spatio-temporels (Camellia et al., 2025). $N = 16$ unités spatiales sur grille 4×4 , $m = 50$ sous-unités par cellule (i, t) , $T = 8$ pas de temps ; confondant latent $U_i \sim \mathcal{N}(0, 1)$.

Table 5 – HCMs ST ($N = 16$, $m = 50$, $T = 8$, force de confondance $c = 2,0$). L’estimateur par unité est quasi-sans-biais pour S4–S5 ; S6 présente un désaccord d’estimand attendu.

Scénario	ATE vrai	Par-unité	OLS naïf	Ratio naïf/vrai
4. Confondant de base	5,00	5,10	27,1	$\times 5,4$
5. Dynamiques linéaires	5,00	5,10	33,0	$\times 6,6$
6. CATE hétérogène	7,06	32,61	35,41	—

Pour S4 et S5, l’OLS naïf est 5 à 7 fois la vraie valeur : U_i confond simultanément la probabilité de traitement et la base de l’outcome, et la régression poolée ne peut pas les séparer. Pour S5, les dynamiques spatio-temporelles amplifient le biais (ratio $\times 6,6$ contre $\times 5,4$ pour S4). Pour S6, le DGP inclut un terme d’interaction spatiale $2 \cdot s_{\text{lag},it} \cdot A_{ijt}$ dans l’outcome : l’estimateur par unité capture CATE_i *plus* ce terme d’interaction qui s’accumule au fil du temps. L’estimand de l’estimateur par unité diffère donc de $\mathbb{E}[\text{CATE}_i]$ — cet écart est attendu et illustre une limitation identifiée du framework dans les DGPs avec interactions traitement-contexte.

Scénarios 7–9 : Benchmarks inspirés de données réelles. Le scénario 7 (29 régions $\times$ 35 segments $\times$ 7 semaines, 7 105 obs.) confirme que l’estimateur par unité récupère -7 mph avec une erreur de 0,04, là où l’OLS naïf surestime le biais de congestion régionale de 40 %. Le scénario 8 présente une forte variance d’échantillonnage ($n = 8$ unités, $\text{SD} \approx 81\text{--}108$ pts SAT) : l’erreur de 4,26 pts est attendue avec si peu d’unités ; l’apport essentiel est qualitatif — le signe est correct ($+4,49$) là où l’OLS naïf donne -17 . Le scénario 9 (NLSY79 synthétique, 50 régions $\times$ 60 individus) illustre le biais d’aptitude classique de Card (1995) : la prime salariale vraie de l’enseignement supérieur est 0,35 en log-salaire, l’estimateur par unité la récupère à

Table 6 – Scénarios inspirés de données réelles. S7 : trafic synthétique Chicago (Camellia et al., 2025). S8 : Huit Écoles (Alderman & Powers, 1979). S9 : NLSY79 synthétique — biais d’aptitude (Card, 1995).

Scénario	ATE vrai	Par-unité	OLS naïf	$ \Delta $
7. Trafic Chicago (synthétique)	−7,00 mph	−7,04	−9,87	0,04
8. Huit Écoles (tutoring SAT)	8,75 pts	4,49	−17,04	4,26
9. NLSY79 — salaires (Card 1995)	0,35 log	0,34	0,70	0,01

0,34 ($|\Delta| = 0,01$), tandis que l’OLS naïf double l’effet (+0,70) en confondant le capital humain régional U_i avec l’effet du diplôme.

8

APPLICATION À PROJECT STAR : ESTIMATION CAUSALE HIÉRARCHIQUE

8.1 PRÉSENTATION ET MOTIVATION

Le projet *Tennessee Student/Teacher Achievement Ratio* (STAR) est l’une des expériences randomisées les plus célèbres en économie de l’éducation [9]. Environ 11 600 élèves de 80 écoles du Tennessee ont été assignés aléatoirement, au sein de chaque école, à l’un de trois types de classes :

- **Petite classe** : 13 à 17 élèves par enseignant,
- **Classe régulière** : 22 à 25 élèves,
- **Classe régulière avec aide** : 22 à 25 élèves avec un assistant.

L’expérience a couvert quatre niveaux scolaires (maternelle à CM1), avec des scores aux tests Stanford Achievement Test (SAT) et Tennessee Basic Skills First (BSF) comme mesures d’outcome.

Malgré la randomisation, les données STAR présentent une structure hiérarchique naturelle : les élèves sont imbriqués dans des classes, elles-mêmes imbriquées dans des écoles. Le traitement (type de classe) est assigné au niveau de la classe, non au niveau de l’élève. Appliquer directement une régression OLS avec effets fixes d’école – comme dans l’approche canonique de (author?) [9] – capture l’effet moyen mais ne modélise pas explicitement ce mécanisme hiérarchique. Les HCM permettent de formaliser précisément : (i) le niveau auquel le traitement opère, (ii) les confondeurs partagés au sein d’une classe, et (iii) la dérivation symbolique de la formule d’identification via le do-calcul.

8.2 DONNÉES ET SCHÉMA HCM

Nous utilisons la cohorte maternelle du fichier `STAR_Students.tab` (Harvard Dataverse, ([author?](#)) 10). Après suppression des valeurs manquantes et limitation à 10 élèves par classe, l'échantillon de travail contient :

Table 7 – Échantillon HCM v2 (cohorte maternelle).

Quantité	Valeur
Élèves	5 745
Classes (unités)	322
Élèves par classe	10
Écoles	79

Table 8 – Variables du modèle HCM v2 STAR.

Variable	Niveau	Définition
A	Sous-unité	$\mathbf{1}\{\text{gkclasstype} = 1\}$ – petite classe
Y	Sous-unité	<code>gktreadss</code> – score de lecture
M	Sous-unité	<code>gktmathss</code> – score de mathématiques
G	Sous-unité	$\mathbf{1}\{\text{genre féminin}\}$
E	Sous-unité	$\mathbf{1}\{\text{race} \in \{\text{blanc, asiatique}\}\}$
L	Sous-unité	$\mathbf{1}\{\text{déjeuner gratuit}\}$
S	Unité	<code>gksurban</code> – urbanicité
U	Unité (latent)	Confondeur latent de niveau classe

Schéma HCM v2 (classe/enseignant $\rightarrow$ élève). L'intervention naturelle est $\text{do}(Q^a = q_\star^a)$: on intervient sur la *distribution* du traitement au sein de la classe, ce qui est la formulation correcte pour une assignation au niveau de la classe.

8.3 PIPELINE D'ANALYSE

L'analyse procède en quatre étapes complémentaires.

1. Découverte causale plate. Nous appliquons PC, FCI, DirectLiNGAM et ExactBIC (`causal-learn`) sur un sous-ensemble de 4000 observations avec 7 variables (`readk`, `mathk`, `stark`, `gender`, `ethnicity`, `lunchk`, `schoolk`). Les graphes obtenus sont ensuite traduits en schémas HCM.

2. Explicabilité prédictive. Une forêt aléatoire est entraînée sur 5 789 observations (114 variables one-hot). L’explicabilité est obtenue via SHAP, LIME et courbes PDP/ICE pour la variable de traitement `stark`.

3. HCM v1 et v2. Deux versions hiérarchiques sont construites : v1 (école $\rightarrow$ élève, 79 unités) comme preuve de concept, et v2 (classe/enseignant $\rightarrow$ élève, 322 unités) comme pipeline principal. Le do-calcul est appliqué sur le modèle collapsé augmenté via pyAgrum.

4. Référence économétrique. Nous répliquons la spécification de (author?) [9] : OLS et 2SLS sur 5 725 observations de maternelle, avec effets fixes d’école et contrôles élève/enseignant.

8.4 RÉSULTATS DE LA DÉCOUVERTE CAUSALE

Table 9 – Jaccard des arcs dirigés entre méthodes (graphes plats sur $n = 4\,000$).

	PC	FCI	LiNGAM	ExactBIC
PC	1,000	1,000	0,667	0,818
FCI	1,000	1,000	0,667	0,818
LiNGAM	0,667	0,667	1,000	0,539
ExactBIC	0,818	0,818	0,539	1,000

Les arcs de consensus (3/3 méthodes) sont `ethnicity` $\rightarrow$ `lunchk`, `gender` $\rightarrow$ `readk` et `schoolk` $\rightarrow$ `lunchk`. Le traitement `stark` n’obtient aucun arc à 2/3 ou 3/3 : cela reflète la difficulté des algorithmes de découverte à retrouver une variable assignée expérimentalement sur des données encodées i.i.d., non un argument contre l’effet causal de la taille de classe. L’estimation DoWhy sur le graphe ExactBIC plat donne $\widehat{ATE}(\text{stark} \rightarrow \text{readk}) = 2,66$, sous-estimant l’effet expérimental documenté.

8.5 EXPLICABILITÉ PRÉDICTIVE

Table 10 – Métriques du modèle prédictif (forêt aléatoire) et contraste PDP.

Indicateur	Valeur
R^2 (test)	0,194
MAE	20,38
RMSE	28,59
Contraste PDP <code>small</code> – <code>regular</code>	+6,45 pts

Le contraste prédictif (+6,45 points) est cohérent avec la littérature expérimentale, mais reste un résultat prédictif et non causal.

8.6 RÉFÉRENCE ÉCONOMÉTRIQUE : RÉPLICATION DE KRUEGER (1999)

Table 11 – Estimations OLS – effet de la petite classe sur le score de lecture (maternelle).

Modèle	$\hat{\beta}_{\text{small}}$	SE	p -value	R^2
Sans contrôles	5,74	1,05	$4,4 \times 10^{-8}$	0,006
Effets fixes école	6,58	0,97	$1,2 \times 10^{-11}$	0,211
+ contrôles élève	6,51	0,94	$3,4 \times 10^{-12}$	0,263
Complet (Krueger)	6,55	0,94	$2,6 \times 10^{-12}$	0,266

L'effet de la petite classe est robuste, de l'ordre de +6,5 points de score de lecture, fortement significatif dans toutes les spécifications. L'effet de la classe avec aide n'est pas significatif. L'estimateur 2SLS (assignation initiale comme instrument pour la taille de classe réelle) donne :

$$\hat{\beta}_{\text{taille classe}} = -0,818 \quad (\text{SE} = 0,109, p = 6,7 \times 10^{-14}),$$

soit environ $-0,82$ point de score par élève supplémentaire.

8.7 HCM v1 : ÉCOLE $\rightarrow$ ÉLÈVE

La première version HCM utilise les 79 écoles comme unités (≈ 34 élèves par école). Les résultats sont numériquement instables :

Table 12 – HCM v1 – ATE par graphe (outcome : lecture).

Graphe	$E[\text{do}(1)]$	$E[\text{do}(0)]$	ATE
PC	436,15	436,15	0,00
FCI	436,15	436,15	0,00
DirectLiNGAM	41 094,66	42 979,48	$-1\,884,82$
ExactBIC	426 106,02	405 421,90	$+20\,684,12$
ConsensusMean	436,15	436,15	0,00

Ces résultats illustrent l'instabilité due au niveau hiérarchique trop grossier : agréger les covariables individuelles (maths, genre, ethnicité) au niveau école supprime la variabilité intra-unité nécessaire à l'identification. Le v1 sert de preuve de concept uniquement.

8.8 HCM v2 : CLASSE/ENSEIGNANT → ÉLÈVE

Avec 322 classes comme unités (≈ 10 élèves par classe), le pipeline HCM v2 est stable pour les cinq graphes.

Table 13 – HCM v2 – ATE par graphe (outcome : mathématiques M , $N_{MC} = 60$, graine = 42).

Graphe	Identifiable	$E[\text{do}(1)]$	$E[\text{do}(0)]$	ATE
PC	Oui	485,91	485,91	0,00
FCI	Oui	485,91	485,91	0,00
DirectLiNGAM	Oui	1 382,54	1 360,27	+22,27
ExactBIC	Oui	2 406,65	2 366,69	+39,96
ConsensusMean	Oui	485,91	485,91	0,00

Formules d’identification (do-calcul, pyAgrum). Pour le graphe **DirectLiNGAM** (outcome M) :

$$\tau_{DL}(q_\star^a) = \sum_{q^e, q^g, q^{l|e}, q^{m|a,e,g,l}, s} p(s | q^e) p(q^{m|a,e,g,l}) p(q^{l|e} | s) \cdot \mathbb{E} \left[Q^m | Q^a = q_\star^a, Q^e, Q^g, Q^{l|e}, Q^{m|a,e,g,l} \right] p(q^g) p(q^e).$$

Pour le graphe **ExactBIC** (outcome M) :

$$\tau_{BIC}(q_\star^a) = \sum_{q^e, q^g, q^{m|e,y}, q^{y|a,g}, s} p(s | q^e) p(q^{y|a,g} | s) p(q^{m|e,y}) \cdot \mathbb{E} \left[Q^m | Q^a = q_\star^a, Q^e, Q^g, Q^{m|e,y}, Q^{y|a,g} \right] p(q^g) p(q^e).$$

Interprétation des ATE nuls. Pour PC, FCI et ConsensusMean, la formule identifiée se réduit à $P(Q^m)$: l’intervention sur Q^a disparaît de l’expression. Un ATE = 0 est donc une conséquence *structurelle* de la topologie du graphe traduit, non une conclusion empirique sur l’absence d’effet de la taille de classe.

Choix du graphe principal. Nous retenons **DirectLiNGAM** comme graphe narratif principal : c’est le seul graphe de découverte produisant un chemin explicite $A \rightarrow M$ dans la traduction HCM, ce qui rend l’estimande directement interprétable comme “effet de la distribution de taille de classe sur le score de mathématiques”. Le graphe ExactBIC (ATE $\approx 39,96$) illustre la sensibilité au choix de structure.

Runs historiques avec identification partielle. Des runs antérieurs (avant la correction du précalcul multi-parents Q , HCM_DISABLE_MULTIPARENT_Q_PRECOMPUTE=1) produisaient :

Table 14 – ATE historiques – facteurs remplacés par 1 (fonctionnelle tronquée $\tilde{\mathfrak{F}}$).

Graphe	ATE historique	Facteurs manquants
DirectLiNGAM	17,618	$P(Q^y g,l,m), P(Q^m a,e,g,l)$
ExactBIC	21,628	$P(Q^y a,g S)$

Dans ces deux cas, l’analyse factorielle montre que la différence $\text{do}(1) - \text{do}(0)$ est quasi entièrement portée par le terme conditionnel principal $P(Q^y | \dots)$ (delta unitaire $\approx +5,33$ points), tandis que les facteurs manquants sont neutralisés multiplicativement à 1. Ces ATE sont *reproductibles* mais représentent une fonctionnelle tronquée $\tilde{\mathfrak{F}} \neq \mathfrak{F}$: leur interprétation causale est affaiblie tant que les estimateurs manquants ne sont pas modélisés.

8.9 SYNTHÈSE COMPARATIVE

Table 15 – Synthèse des estimations de l’effet de la petite classe (STAR, maternelle).

Méthode	Données	Outcome	Effet estimé
Découverte causale (DoWhy/ExactBIC)	4 000 obs.	Lecture	+2,66 pts
RF prédictif (PDP/ICE)	5 789 obs.	Lecture	+6,45 pts (prédictif)
OLS complet (Krueger)	5 725 obs.	Lecture	+6,55 pts***
2SLS (instrument taille classe)	5 725 obs.	Lecture	−0,82 pt/élève***
HCM v1 (école → élève)	5 768 obs.	Lecture	Non crédible
HCM v2 – DirectLiNGAM	5 745 obs.	Maths	+ 22,27 pts
HCM v2 – ExactBIC	5 745 obs.	Maths	+39,96 pts

Note de comparabilité. Les estimations OLS/2SLS ciblent le score de lecture sur l’échelle centile SAT ; les ATE HCM v2 ciblent le score brut de mathématiques (**gkmathss**). Ces deux outcomes ont des échelles et des mécanismes différents, rendant la comparaison directe point à point abusive. Le sens positif de l’effet de la petite classe est cohérent entre toutes les méthodes ; la baseline OLS ($\approx +6,5$ centiles) reste la référence substantive pour l’ordre de grandeur économétrique.

8.10 APPORT DES HCM POUR STAR

Le cadre HCM apporte trois contributions méthodologiques précises par rapport aux approches standards sur STAR.

Niveau d'intervention correct. L'OLS standard définit le traitement au niveau élève ($\text{SMALL}_{ics} = 1$). Or, le type de classe est assigné au niveau classe. Le HCM intervient sur Q^a , la *distribution* du traitement au sein de la classe, qui est la formulation naturelle pour une assignation de niveau classe.

Structure hiérarchique explicite. Le graphe HCM v2 distingue les variables de niveau classe (S, U) des variables de niveau élève (A, Y, M, G, E, L). Cela permet de représenter le fait que l'urbanité de l'école façonne le mécanisme traitement-outcome à un niveau différent des caractéristiques individuelles.

Identification symbolique via do-calcul. Plutôt que de supposer un ensemble de backdoor à ajuster, le pipeline HCM applique le do-calcul sur le graphe collapsé augmenté et dérive symboliquement la formule d'identification. Les hypothèses d'identification sont ainsi explicites et vérifiables, ce qui renforce la transparence par rapport à l'OLS avec effets fixes.

Positionnement par rapport à l'état de l'art. À notre connaissance, aucune implémentation existante ne combine découverte causale, identification HCM par do-calcul et estimation plug-in dans un pipeline unifié appliqué à des données hiérarchiques réelles. La bibliothèque `y0` (`y0-causal-inference`) a récemment introduit un support symbolique des HCM (janvier 2025) permettant de dériver des formules d'identification dans un DSL qui s'étend jusqu'au transport contrefactuel. Cependant, leur implémentation se limite à la dérivation symbolique et n'inclut pas d'estimation (ni ajustement de familles de distributions, ni évaluation numérique de la formule, ni calcul d'ATE à partir de données). Leur framework d'estimation `eliater` a été archivé peu avant leur PR HCM. Le présent travail constitue ainsi, à notre connaissance, le premier pipeline HCM de bout en bout, de la donnée brute à l'ATE estimé.

8.11 BENCHMARK DES FAMILLES DE DISTRIBUTIONS

Analyse distributionnelle des scores. Les scores de lecture (`gktreadss`) et de mathématiques (`gktmathss`) dans STAR sont des variables continues bornées, avec un support empirique approximativement dans $[300, 650]$. Un ajustement Gaussien, une loi log-normale et une loi de Student- t ont été comparés par critère AIC sur l'échantillon complet ($n = 5\,745$). La distribution intra-classe présente une asymétrie légère et des queues plus épaisses que la Gaussienne, ce qui motive l'utilisation de mélanges Gaussiens (GMM, $K = 2$) ou de familles plus expressives.

Protocole de benchmark. Pour tester la sensibilité de l'ATE HCM au choix de famille de distributions pour les outcomes Y et M , nous avons comparé quatre variantes sur un sous-échantillon de 28 classes (`star_variational_families_benchmark.py`, `star_baseline_and_hcm_benchmark.py`) :

- **Gaussienne** (`gaussian`) : famille de base ; sous-estime les queues épaisses.

- **Bêta normalisée** (`beta`) : scores linéairement re-normalisés dans $(0, 1)$, famille $\text{Beta}(\alpha, \beta)$.
- **Gamma décalée** (`gamma`) : $Y - \min(Y) + \varepsilon$, adapte les scores à support positif.
- **Mélange Gaussien** (`gaussian_mixture`, $K = 2$) : famille choisie dans le pipeline principal ; capture les modes multiples potentiels dus à l'hétérogénéité enseignant.

Table 16 – Benchmark des familles – $E[\text{do}(1)]$ et ATE par famille (outcome Y , graphe PC sur 28 unités, backend numpy).

Graphe	Famille Y	Statut	$E[\text{do}(1)]$	ATE
PC	<code>gaussian</code>	ok	430,21	0,00
PC	<code>beta</code>	ok	5,11	0,00
PC	<code>gamma</code>	ok	7,10	0,00
PC	<code>gaussian_mixture</code>	ok	0,61	0,00
DirectLiNGAM	toutes familles	erreur	—	—

Interprétation. Pour le graphe PC, la formule identifiée est $P(Q^y)$ indépendamment de la famille de distribution – l'ATE est nul par construction pour ce graphe, quelle que soit la famille. La valeur de $E[\text{do}(1)]$ change d'échelle selon la renormalisation (brut : 430, bêta : 5,1, mélange : 0,6) sans affecter la conclusion sur l'ATE. Les graphes DirectLiNGAM et Exact-BIC rencontrent une erreur de dimension (`X has 6 features, but LinearRegression is expecting 4`) dans ce benchmark antérieur à l'alignement régresseurs – erreur corrigée dans le pipeline principal v2 (Tableau 13). Le mélange Gaussien ($K = 2$) reste la famille la plus expressive disponible et est retenu comme famille principale pour les outcomes continus dans le pipeline v2.

Note sur la structure à trois niveaux. STAR présente en réalité une structure à *trois* niveaux : élèves $\subset$ classes $\subset$ écoles. Le cadre HCM tel qu'implémenté supporte deux niveaux (unités et sous-unités). Deux stratégies d'agrégation sont possibles :

1. **Agrégation élèves $\rightarrow$ classe (retenue)** : les classes deviennent les unités (niveau 1), les élèves les sous-unités (niveau 2). L'école est une covariable de niveau unitaire ($S = \text{gksurban}$). C'est la stratégie v2 retenue, qui colle au mécanisme de randomisation (le traitement est assigné au niveau classe).
2. **Agrégation classes $\rightarrow$ école** : les écoles deviennent les unités, les classes les sous-unités. Cette formulation perd la variabilité intra-classe et ne capture pas directement le mécanisme de traitement.

L'extension des HCM à des hiérarchies à trois niveaux (élève $\subset$ classe $\subset$ école) constitue une direction de recherche ouverte, qui permettrait de modéliser simultanément les effets de pairs au niveau classe et les effets d'établissement au niveau école.

9

DISCUSSION

9.1 ENSEIGNEMENTS CLÉS

Les données hiérarchiques comme ressource pour l’identification. Le message central du cadre HCM—et ce que nous avons validé expérimentalement—est que les données hiérarchiques peuvent transformer des problèmes non identifiables en problèmes identifiables. La régression par unité conditionne implicitement sur la variable confondante latente au niveau de l’unité en traitant les données de sous-unités de chaque unité comme un problème de régression séparé.

Le rôle des variables Q . Les variables Q sont le pont conceptuel entre le monde hiérarchique et le monde plat. En rendant explicite l’aléatoire au niveau de l’unité comme des distributions aléatoires (plutôt que des variables aléatoires scalaires), le cadre HCM permet d’appliquer les outils standard des modèles graphiques causaux. Le modèle collapsé est un CGM ordinaire, et les algorithmes d’identification existants fonctionnent sans modification.

Le do-calcul comme moteur d’identification. L’utilisation du do-calcul via pyAgrum permet une identification entièrement automatique : étant donné un nouveau HCM, le pipeline identifie, parse et estime sans codage manuel de l’estimateur. La règle 2 du do-calcul (échange action/observation) est particulièrement centrale dans les HCM, car elle permet de remplacer les interventions sur les variables Q par des observations.

9.2 LIMITATIONS ET PROBLÈMES OUVERTS

Hypothèse de m grand. Les garanties théoriques reposent sur la limite m grand (beaucoup de sous-unités par unité). En pratique, avec m petit, les estimations par unité sont bruitées.

Hiérarchies multi-niveaux. Le cadre traite deux niveaux (unités, sous-unités) mais de nombreux jeux de données réels ont un emboîtement plus profond. Étendre les HCM aux hiérarchies à K niveaux est un problème ouvert.

Positivité et chevauchement. L’identification requiert la positivité. En pratique, les violations de positivité peuvent conduire à une grande variance de l’estimateur.

10

CONCLUSION

Ce PSC nous a fourni une compréhension approfondie du cadre des Modèles Causaux Hiérarchiques de Weinstein et Blei (2023), ainsi qu’une expérience pratique d’implémentation et de validation expérimentale.

Théorie. Nous avons compris et redérivé les résultats théoriques clés : les transformations de graphes collapse/augment/marginalize, la réduction de l’identification HCM au do-calcul sur le modèle effondré plat, et les trois stratégies d’identification (porte arrière, porte avant, VI) pour les trois motifs canoniques.

Implémentation. Nous avons construit un package Python complet articulé autour du pipeline :

1. `collapse(hscm)` : transformation du HSCM en CGM plat.
2. `suggest_augment_for_outcome(hscm, Y)` : suggestion des variables Q à ajouter.
3. `augment_collapsed_model(collapsed, q_hat, parents)` : augmentation variable par variable.
4. `marginalize_augmented_model(augmented, q_hat, parents)` : marginalisation si nécessaire.
5. `identify_effect(cgm, Y, X)` : identification automatique via do-calcul pyAgrum.
6. `estimate_causal_effect(result, data, intervention)` : estimation numérique à partir du DoCalculusResult.

Expériences. Nous avons validé la récupération de l’ATE sur les trois motifs HCM, confirmé les 11 cas de test du do-calcul, et démontré la généralité du cadre sur 5 familles de distributions.

Travaux futurs. Les extensions prometteuses incluent : les hiérarchies multi-niveaux, l’estimation bayésienne hiérarchique (pour m petit), l’analyse de sensibilité aux violations de positivité, et les applications à des jeux de données réels (éducation, biologie, sciences politiques).

REMERCIEMENTS

Nous remercions les auteurs de l’article HCM, Eli N. Weinstein et David M. Blei, pour leur exposé clair et approfondi. Nous remercions également nos superviseurs de PSC : David Corrés(X97) et Janis Aiad(X22), pour leurs conseils et encadrement tout au long du projet.

RÉFÉRENCES

RÉFÉRENCES

- [1] Weinstein, E. N. et Blei, D. M. (2023). *Hierarchical Causal Models*. arXiv preprint arXiv :2301.xxxxxx.
- [2] Pearl, J. (2009). *Causality : Models, Reasoning and Inference*. Cambridge University Press, 2^e édition.
- [3] Peters, J., Janzing, D. et Schölkopf, B. (2017). *Elements of Causal Inference*. MIT Press.
- [4] Imbens, G. W. et Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- [5] Rubin, D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66(5) :688–701.
- [6] Angrist, J. D., Imbens, G. W. et Rubin, D. B. (1996). Identification of causal effects using instrumental variables. *Journal of the American Statistical Association*, 91(434) :444–455.
- [7] Gonzales, C., Torti, L. et Willemin, P.-H. (2017). aGrUM : a graphical models framework. *Proceedings of the 10th International Conference on Scalable Uncertainty Management*.
- [8] Wooldridge, J. M. (2005). Fixed-effects and related estimators for correlated random-coefficient and treatment-effect panel data models. *Review of Economics and Statistics*, 87(2) :385–401.
- [9] Krueger, A. B. (1999). Experimental estimates of education production functions. *The Quarterly Journal of Economics*, 114(2) :497–532.
- [10] Achilles, C., Bain, H. P., Bellott, F., Boyd-Zaharias, J., Finn, J., Folger, J., Johnston, J. et Word, E. (2008). *Tennessee’s Student Teacher Achievement Ratio (STAR) Project*. Harvard Dataverse.
- [11] Krueger, A. B. et Whitmore, D. M. (2001). The effect of attending a small class in the early grades on college-test taking and middle school test results : evidence from Project STAR. *The Economic Journal*, 111(468) :1–28.
- [12] Chetty, R., Friedman, J. N., Hilger, N., Saez, E., Schanzenbach, D. W. et Yagan, D. (2011). How does your kindergarten classroom affect your earnings ? Evidence from Project STAR. *The Quarterly Journal of Economics*, 126(4) :1593–1660.

- [13] Hanushek, E. A. (1999). Some findings from an independent investigation of the Tennessee STAR experiment and from other investigations of class size effects. *Educational Evaluation and Policy Analysis*, 21(2) :143–163.

A

TRANSFORMATIONS DE GRAPHS COMPLÈTES

A.1 CONFONDANT : TRANSFORMATION COMPLÈTE




Figure 6 – Confondant : transformations complètes. (a) HCM original avec plaques. (b) Modèle collapsé : Q_i^a et $Q_i^{y|a}$ sont deux variables aléatoires confondues par U_i . (c) Modèle augmenté : ajout de Q_i^y (double flèche = fonction déterministe) avec parents Q_i^a et $Q_i^{y|a}$. (d) Modèle marginalisé : identique à l’augmenté ici, car la positivité est satisfaite. Le do-calcul sur (c)/(d) identifie $p(Q^y | \text{do}(Q^a = q_\star^a)) = \mathbb{E}_{Q^{y|a}}[\sum_a q_\star^a(a) Q^{y|a}(a)]$.

A.2 CONFONDANT ET INTERFÉRENCE : TRANSFORMATION COMPLÈTE




Figure 7 – Confondant et Interférence : transformations complètes. (a) HCM original : A_{ij} agrège vers Z_i (interférence), U_i confond A_{ij} et Y_{ij} . (b) Modèle collapsé : structure de porte avant $Q_i^a \rightarrow Z_i \rightarrow Q_i^{y|a}$, avec U_i confondant Q_i^a et $Q_i^{y|a}$ mais pas Z_i . (c) Modèle augmenté : ajout de Q_i^y (double flèche) avec parents Q_i^a et $Q_i^{y|a}$; le médiateur Z_i est la clé de l'identification via la porte avant. La formule obtenue est : $p(Q^y \mid \text{do}(Q^a=q_\star^a)) = \sum_z p(Q_i^{y|a} \mid Z=z) p(Z=z \mid Q^a=q_\star^a)$.

A.3 INSTRUMENT : TRANSFORMATION COMPLÈTE




Figure 8 – Instrument : transformations complètes. (a) HCM original : Z_{ij} instrument sous-unité, A_{ij} traitement sous-unité, Y_i résultat unité ; U_i confond A_{ij} et Y_i mais est indépendant de Z_{ij} . (b) Modèle collapsé : Z_{ij} et A_{ij} deviennent Q_i^z et $Q_i^{a|z}$; U_i confond $Q_i^{a|z}$ et Y_i , mais Q_i^z reste non confondant. (c) Modèle augmenté : ajout de Q_i^y (double flèche) avec parents $Q_i^{a|z}$ et Q_i^z ; Q_i^y n'est pas directement identifiable car Q_i^z viole la positivité, ce qui nécessite la marginalisation. (d) Modèle marginalisé : suppression de Q_i^z ; sur ce graphe le do-calcul (Règle 2) s'applique directement. La formule identifiée est : $p(Y \mid \text{do}(A \sim q_\star^a)) = \mathbb{E}_{Q^{a|z}, Q^z} \left[\frac{q_\star^a(a)}{Q^{a|z}(a|z)} Y \right]$.